

1. הקדמה (Introduction)

רובוטים הפועלים בסביבה דינמית חייבים להבין ולהגיב לרצף של מצבים ופעולות לאורך זמן. החלטותיהם אינן יכולות להיקבע על סמך תמונה יחידה, אלא מתוך ניתוח של מספר רגעים רציפים. האתגר המרכזי בעבודה עם קלט חזותי גולמי (תמונות) הוא כמות הפרטים העצומה בכל פריים – תאורה, רקע, הסתרות ורעש – המקשה על למידה ישירה.

אתגר נוסף המאפיין למידה מנתוני רובוטיקה קשור בתהליך עיבוד וסינון המידע (Data Curation). הסתמכות על מדדים קינמטיים קשיחים בלבד (כגון מידת הסגירה של הגריפר) כדי לקבוע את סטטוס המשימה עלולה להיות מוגבלת מטבעה. לדוגמה, כאשר רובוט מתמרן אובייקטים רכים או דחיסים, הנתונים הפיזיים עשויים שלא לשקף נאמנה את המצב בפועל. כדי לייצר תשתית נתונים יציבה ומדויקת יותר, אחת המטרות שלי בפרויקט היא לבחון ולשלב מנגנוני סינון המבוססים על ניתוח חזותי (ראייה ממוחשבת) המסוגלים להשלים את החוסרים של החיישנים הפיזיים.

בפרויקט זה אני מתמקדת בפיתוח מערכת מקצה-לקצה (End-to-End) לחיקוי התנהגות (Behavioral Cloning), אשר לומדת את התלות הטמפורלית וחוזרה ברציפות את פעולת הרובוט הבאה – משמע, מפיקה פלט של וקטור בעל 7 דרגות חופש (Action). כדי לפתור את רגישות הרעש של קלט הפיקסלים הגולמי, אני משתמשת במקודד חזותי מסוג OpenCLIP, הממיר כל תמונה לווקטור תכונות קומפקטי ויציב. לאחר מכן, רצף וקטורי התכונות הללו משורשר לנתוני המצב (States) ומוזן למודל Mamba – מודל מסוג State-Space המתאפיין ביעילות חישובית גבוהה ומיועד ללמידת תלויות ברצפים ארוכים. שילוב זה מאפשר למערכת ללמוד את הדינמיקה בציר הזמן, להבין את ההקשר הפיזיקלי של הפעולה, ולספק חיזוי מדויק של הצעד הבא הנדרש בכל רגע נתון.

2. תיאור כללי של המערכת (System Overview)

המערכת שאני מפתחת בנויה כ-Pipeline בשלבים, המפריד בין עיבוד המידע החזותי לבין למידת התלות בזמן, ונועד להפיק חיזוי של הפעולה הבאה של הרובוט (Action). קלט המערכת הוא רצף של תמונות (וידאו/פריימים) מחלון זמן קבוע מראש, יחד עם נתוני המצב הקינמטיים התואמים לכל פריים (למשל, מצב המפרקים או הגריפר).

הזרימה (Flow) המרכזית במערכת מתבצעת באופן הבא:

2.1 סינון וסנכרון נתונים מקדים (Data Curation & Synchronization):

בשלב הראשון, המערכת מתוכננת להעביר את הנתונים הגולמיים דרך שכבת סינון אוטומטית. המטרה של מודול זה היא לנפות מידע רועש (כגון פריימים פגומים או שחורים) ולבודד את חלונות הזמן המשמעותיים ללמידה. לאחר ניקוי הנתונים, מתבצע סנכרון מדויק בין רצפי התמונות התקינים לבין נתוני המצב של הרובוט באותן נקודות זמן.

2.2 חילוף מאפיינים חזותיים (Visual Encoding):

התמונות המסוננות מומרות לסנזורים ומוזנות למקודד החזותי OpenCLIP (מדגם ViT-B-32). מודל זה, המאומן מראש, מפיק עבור כל תמונה וקטור תכונות (Embedding) קומפקטי ויציב בגודל קבוע של 512 ממדים, המרכז את התוכן החזותי הרלוונטי.

2.3 מיזוג מולטי-מודאלי (Fusion):

עבור כל צעד זמן, הוקטור החזותי (512 ממדים) משורשר (Concatenated) עם וקטור נתוני המצב הקינמטיים של הרובוט באותו הרגע (7 ממדים, הכוללים לרוב את זוויות המפרקים ומצב הגריפר). פעולה זו יוצרת וקטור קלט מאוחד ועשיר בגודל כולל של 519 ממדים המייצג את מצב המערכת הפיזי והחזותי גם יחד.

2.4 עיבוד טמפורלי וחיזוי פעולה:

הרצף המאוחד של הוקטורים (בצורת טנזור בעל ממד קלט של 519) מוזן לרשת Mamba (State-Space Model). המודל מעביר את המידע דרך שכבת השלכה (Input Projection) ומעבד את התלות ההיסטורית בחלון הזמן. לבסוף, מתוך הייצוג הפנימי של

הצעד האחרון ברצף, המודל גוזר באמצעות שכבת פלט ליניארית (Action Head) את תחזית 7 דרגות החופש לפעולה הבאה הנדרשת (Predicted Action).

3. הנחות והחלטות עיצוב (Assumptions & Design Decisions)

3.1 עקרונות תשתית

3.1.1 עיבוד מקדים סטנדרטי לקלט החזותי: המערכת מבצעת עיבוד מקדים (Pre-processing) לכל תמונת גלם המגיעה מה-dataset. התמונות משנות את גודלן (Resize) למידות קבועות של 224X224 פיקסלים ועוברות נרמול, זאת כדי לעמוד בדרישות הקלט הקשיחות של ארכיטקטורת ViT-B-32 עליה מבוסס מודל הראייה.

3.1.2 ייצוג תכונות חזותי (Embedding): כדי לאפשר למודל להתמקד במידע סמנטי ודינמי ולנטרל רעשי פיקסלים, המערכת משתמשת במקודד OpenCLIP מאומן מראש. המקודד ממפה כל תמונה מעובדת לוקטור מאפיינים קומפקטי בגודל של 512 ממדים. ייצוג זה מספק בסיס יציב ועמיד לשינויי תאורה או זוויות צילום.

3.1.3 יעילות חישובית ברצפים ארוכים: המערכת מתבססת על מודל Mamba כליבת עיבוד הרצף. הבחירה בארכיטקטורת State Space Model מאפשרת למערכת לשמור מידע משלבים קודמים לאורך זמן בסיבוכיות חישובית ליניארית (ביחס לאורך הרצף), מה שמבטיח עבודה יעילה גם ברצפים הכוללים מאות פריימים.

3.1.4 אינטגרציה מולטי-מודאלית: המערכת מאחדת בין הידע החזותי לנתונים הקינמטיים של הרובוט. בכל צעד זמן, המערכת משרשרת את וקטור המצב הקינמטי (7 ממדים) לוקטור התכונות החזותי (512 ממדים), ליצירת וקטור קלט אחוד בגודל 519 ממדים. איחוד זה מספק למודל את מלוא ההקשר הנדרש לחיזוי הפעולה הבאה.

3.2 החלטות עיצוב (Design Decisions)

3.2.1 מנגנון סינון נתונים (Data Curation) מבוסס ראייה: כחלק מארכיטקטורת המערכת, הוגדר מודול ייעודי לסינון נתונים חזותי. החלטה זו התקבלה כדי להתגבר על מגבלות של חיישנים פיזיים באיתור מצבי הצלחה/כישלון (למשל בעת מגע עם אובייקטים דחיסים). המודול נועד לנפות באופן אוטומטי פריימים שאינם תקינים ולבודד את חלונות הזמן הרלוונטיים לפעולה (כגון רגע האחיזה) מתוך כלל המסלול.


3.2.2 שימוש במקודד ראייה קפוא (Pre-trained Encoder): בחרתי להשתמש במשקולות המאומנות מראש של OpenCLIP ללא אימון מחדש (Fine-tuning) של רשת הראייה בשלב זה. החלטה זו מאפשרת לנצל ידע חזותי רחב שנלמד על מיליוני תמונות, חוסכת משאבי חישוב משמעותיים ומבטיחה יציבות בייצוג התכונות.

3.2.3 מודל Mamba כליבת הרצף: לאחר בחינת חלופות (RNN ו-Transformer), הוחלט על שימוש ב-Mamba בשל השילוב האופטימלי בין זיכרון ארוך טווח ליעילות בזמן ריצה. בניגוד ל-Transformer, המודל מאפשר עיבוד מהיר ללא דרישות זיכרון ריבועיות, ובניגוד ל-RNN הוא נמנע מבעיות של שכחת מידע ברצפים ארוכים.

3.2.4 מודולריות והפרדת אחריות: המערכת מתוכננת במבנה מודולרי המפריד בין ה-Visual Encoder לבין ה-Sequence Decoder. הפרדה זו מאפשרת תחזוקה נוחה, יכולת לשדרג כל רכיב בנפרד (למשל החלפת מודל הראייה), ומבטיחה שכל רכיב יתמקד במשימה הייעודית לו: הבנת התמונה לעומת הבנת הדינמיקה בזמן.

4. תרשים ארכיטקטורה (Architecture Diagram)

ארכיטקטורת המערכת מבוססת על Pipeline טורי המחולק לארבעה שלבים לוגיים, המפרידים בין הבנת הסצנה הוויזואלית לבין למידת הדינמיקה והתלות בזמן.



4.1

פירוט שלבי העיבוד:

- 4.1.1 Stage 1: Input & Prep** – שלב זה מקבל את נתוני ה-Trajectory הגולמיים הכוללים רצף תמונות ומצבי רובוט. התמונות עוברות שינוי גודל ל-224X224 וסינון חזותי (Curation Filter) לניקוי נתונים פגומים, בעוד נתוני המצב (Kinematic State) נשלפים כווקטור של 7 ממדים.
- 4.1.2 Stage 2: Visual Encoding** – המערכת משתמשת במודל OpenCLIP (ViT-B-32) כדי לחלץ מכל פריים מעובד ווקטור מאפיינים (Embedding) בגודל 512 ממדים.
- 4.1.3 Stage 3: Data Fusion** – בשלב זה מתבצע איחוד (Concatenate) של המידע החזותי והקינמטי לכדי וקטור קלט מאוחד (Fused Vector) בגודל 519 ממדים לכל צעד זמן.
- 4.1.4 Stage 4: Sequence Modeling** – הרצף המאוחד מוזן למודל Mamba SSM. המודל לומד את ההקשר הטמפורלי וחוזר דרך ה-Action Head את הפעולה הבאה ברמת 7 דרגות חופש (DOF).

5. ממשקים ומימוש תוכנה (Software Interfaces & API)

פרק זה מפרט את המבנה הלוגי של המחלקות והפונקציות המרכזיות בפרויקט, תוך חלוקה למודולים פונקציונליים השומרים על מודולריות המערכת.

5.1 ממשק המשתמש והשליטה (UI - app.py)

הממשק ממומש באמצעות ספריית Streamlit (הממוקם בתיקיית UI/app.py) ומהווה את שכבת הבקרה והוויזואליזציה המרכזית של המערכת. הממשק מאפשר שליטה מלאה בפרמטרים הטכניים של המודל ושל תהליך הלמידה.

- **לוח בקרה ותצורת המערכת (Configuration Panel):** הממשק כולל Sidebar המאפשר הגדרה דינמית של פרמטרי הריצה והאימון:
 - **Data Source Validation:** הזנת נתיב לתיקיית הניסוי (Trajectory Path) עם מנגנון בדיקה אוטומטי המוודא קיום קבצי קלט תקינים (כגון obs_dict.pkl ו-policy_out.pkl).
 - **Model Hyperparameters:** שליטה באורך חלון הזמן (K) ובממד המרחב החבוי של הרשת (d_model).
 - **Training Configuration:** הגדרת פרמטרי האימון הכוללים את מספר האפוקים המקסימלי (Max Epochs), גודל ה-Batch, וערך ה-Patience עבור מנגנון ה-Early Stopping.
- **ניהול תהליך האינפרנס (Inference Pipeline):** בלחיצה על כפתור ההפעלה, המערכת מפעילה רצף פעולות המלווה בסרגל התקדמות (Progress Bar) בזמן אמת, הכולל חילוץ Embeddings מ-OpenCLIP והרצת מודל ה-Mamba על הנתונים הנבחרים.
- **מנגנון שמירת נתונים (Persistence):** המערכת כותבת את תוצאות כל ריצה (Inference) לקובץ לוג ייעודי (inference_log.csv) הכולל את החיזוי מול ה-Ground Truth. קובץ זה משמש בסיס להצגת גרפים השוואתיים רציפים המציגים את סטיית המודל בכל אחד מ-7 ממדי הפעולה לאורך זמן.
- **מטריקות ויזואליות:** תצוגת לוח מחוונים הכולל את שגיאת ה-MAE, זמן האינפרנס, ותצוגה של רצף התמונות (Last 5 Frames).

5.2 מקודד חזותי (openclip_embed.py)

- מחלקה ייעודית המבודדת את שלב חילוץ המאפיינים הוויזואליים.
- **שם המחלקה:** OpenClipEncoder.
- **תפקיד:** טעינת מודל ה-ViT-B-32 במצב הערכה (eval). המודל ממיר תמונות מעובדות בגודל 224X224 לווקטורים סמנטיים של 512 ממדים.

5.3 מודול טעינת הנתונים (data_loader.py)

- המחלקה המתווכת בין הקבצים הגולמיים של ה-BridgeData לבין המודל.
- **שם המחלקה:** MultiModalRoboticDataset.

- **פונקציות עיקריות:**
 - **Preprocessing:** שינוי גודל תמונה ל-224X224, נרמול והמרתה לסנזור.
 - **Feature Fusion:** שימוש ב-OpenClipEncoder לחילוף וקטור חזותי (512 ממדים) ושרשורו לנתוני המצב הקינמטי (7 ממדים) ליצירת וקטור קלט אחוד בגודל 519 ממדים.
- 5.4 מודול המודל (mamba_model.py)**
 - מחלקה המגדירה את ארכיטקטורת רשת ה-SSM המולטי-מודאלית:
 - **שם המחלקה:** MultimodalMambaBC.
 - **מבנה המודל:** כולל שכבת input_proj למיפוי הקלט למרחב החבוי, בלוק mamba לעיבוד טמפורלי של הרצף, ושכבת action_head לחיזוי וקטור הפעולה של הרובוט.
- 5.5 סקריפטים לניהול מחזור חיים (train.py & evaluate.py)**
 - **אימון (train.py):** מנהל את תהליך הלמידה הכולל Split ל-Train/Val, חישוב Loss ויישום מנגנון Early Stopping לפי הפרמטרים שהוגדרו במערכת.
 - **הערכה (evaluate.py):** ביצוע בדיקה של המודל על נתונים חדשים, חישוב שגיאת ה-MAE מול ה-Ground Truth והפקת נתונים לקובץ הלוג של ה-UI.
- 6. מידע ונתונים (Information & Data)**

פרק זה מפרט את מקורות המידע, מבנה הנתונים הספציפי, והטרנספורמציות המיושמות על מנת להכין את הנתונים הגולמיים לאימון המודל.

- 6.1 מקור הנתונים ומיקוד המשימה (Dataset & Task Focus)**

הפרויקט מתבסס על דאטהסט ה-BridgeData V2, אך אינו עושה שימוש בכלל המשימות המצויות בו.

 - **סינון משימות (Pick and Place):** כדי לייצר מודל בעל יכולת למידה ממוקדת, בחרתי לסנן את הדאטהסט ולהתאמן אך ורק על משימות של הזזת חפצים (Pick and Place), המאוחסנות תחת תת-התיקיה npk.
 - **הצדקה:** מיקוד זה מבודד את הלמידה הקינמטית של תפיסה (Grasping) ומיקום (Placing), ומונע הכנסת רעש ממשימות בעלות אופי דינמי שונה (כמו קיפול או ניגוב), מה שמשפר את יציבות האימון.
- 6.2 הפלטפורמה הרובוטית - WidowX-250**

הנתונים נאספו באופן בלעדי מרובוט מסוג WidowX-250 6DOF.

 - **מרחב הפעולה (Action Space):** לזרוע יש 6 דרגות חופש (6-DOF) במפרקים, בתוספת דרגת חופש אחת עבור הגריפר. יחד, הם מגדירים מרחב פעולה רציף של 7 ממדים שאותו המודל נדרש לחזות.
 - **חיישנים:** המידע הנאסף כולל וידאו ממצלמת RGB הממוקמת על הרובוט (או בסביבתו) ומספקת את ההקשר החזותי, לצד נתוני חיישני המפרקים המדווחים על מצב הזרוע.
- 6.3 מבנה נתוני המסלול (Trajectory Data Structure)**

מבנה התיקיות שבו המערכת תומכת מוגדר במדויק מתוך ה-npk. כל מסלול (לדוגמה: raw/traj_group0/traj9) כולל את הקבצים הבאים:

 - **obs_dict.pkl:** קובץ מילון (Dictionary) המכיל את התצפיות (Observations). מתוך קובץ זה נשלף וקטור המצב הקינמטי (Kinematic State) בגודל 7 ממדים לכל צעד זמן מוגדר.
 - **policy_out.pkl:** קובץ המכיל את הפעולה הפיזית שבוצעה בפועל ב-Trajectory (Ground Truth). וקטור זה, בגודל 7 ממדים, משמש כיעד (Target) לחישוב פונקציית ההפסד (Loss) באימון.
 - **קבצי תמונה (.png / .jpg):** רצף הפריימים החזותיים התואמים לכל צעד זמן ב-obs_dict.pkl.
- 6.4 צינור עיבוד נתונים (Data Pipeline & Preprocessing)**

על מנת להזין את הנתונים לרשת ה-Mamba, הנתונים הגולמיים עוברים עיבוד המנוהל על ידי מודול ה-DataLoader:

- **עיבוד תמונה:** שינוי גודל כל פריים לממדים של 224X224 פיקסלים, התואמים לדרישות הקלט של רשת ה-ViT ב-OpenCLIP.
- **חילוץ מאפיינים (Feature Extraction):** כל תמונה מועברת ב-OpenCLIP ליצירת ייצוג וקטורי דחוס בגודל 512 ממדים.
- **איחוד וקטורי (Data Fusion):** וקטור התמונה (512 ממדים) משורשר (Concatenated) יחד עם נתוני המפרקים מ-obs_dict.pkl (7 ממדים) ליצירת וקטור קלט סופי בגודל 519 ממדים.
- **בניית רצפים (Sequence Windowing):** וקטורי ה-519 ממדים נדגמים בחלונות זמן באורך K (הנקבע דינמית דרך ה-UI, ברירת מחדל K=10), כדי לספק למודל ה-Mamba הקשר טמפורלי רציף של התנועה.

7. בדיקות והערכה (Testing and Evaluation)

פרק זה מגדיר את המתודולוגיה להערכת ביצועי המודל המולטי-מודאלי, תוך התייחסות למדדי שגיאה כמותיים, שיטות התיקוף (Validation) ויכולות העיבוד בזמן אמת.

7.1 מדדי ביצוע כמותיים (Quantitative Metrics)

הערכת הביצועים מתבססת על שני מדדים מרכזיים המוצגים בזמן אמת בממשק המשתמש:

- **שגיאה מוחלטת ממוצעת (Mean Absolute Error - MAE):** המדד המרכזי להערכת דיוק המודל. המערכת מחשבת את הסטייה המוחלטת בין וקטור הפעולה החזוי על ידי ה-Action Head (7-DOF) לבין וקטור הפעולה האמיתי (Ground Truth) הנשלף מקובץ ה-policy_out.pkl.
- **זמן הסקה (Inference Latency):** מדידת זמן העיבוד הנדרש להפקת פעולה (במילי-שניות) מרגע קבלת התמונה ונתוני המצב. המטרה היא לוודא שארכיטקטורת ה-Mamba וה-OpenCLIP מסוגלות לעבוד בקצב המאפשר תגובה בזמן אמת של הרובוט.

7.2 מתודולוגיית אימון ותיקוף (Training & Validation Strategy)

כדי להבטיח שהמודל מסוגל לבצע הכללה (Generalization) למשימות Pick and Place חדשות, מיושמת האסטרטגיה הבאה:

- **הפרדת נתונים (Trajectory-Level Split):** חלוקת מאגר הנתונים לאימון (Train) ולידיציה (Validation) מתבצעת ברמת המסלול המלא (Trajectory) ולא ברמת הפריים הבודד. גישה זו מונעת דליפת נתונים (Data Leakage) ומבטיחה שהמודל נבחן על משימות שלמות שלא ראה בעבר.
- **עצירה מוקדמת (Early Stopping):** המערכת מנטרת את פונקציית ההפסד על קבוצת הוולידציה לאורך האפוקים (Epochs). אם אין שיפור במשך מספר מוגדר של אפוקים (ערך ה-Patience המוגדר ב-UI), האימון נעצר אוטומטית למניעת התאמת יתר (Overfitting), והמשקלים האופטימיים נשמרים.

8. כלים וסביבות פיתוח (Tools & Development Environments)

פרק זה מפרט את מחסנית הטכנולוגיות (Tech Stack), סביבות העבודה והספריות המרכזיות שעליהן מבוססת המערכת, כפי שהוגדרו בקבצי התצורה של הפרויקט.

8.1 שפת פיתוח ותשתיות ליבה

- **שפת תכנות:** הפרויקט מפותח ב-Python (גרסה 3.10+).
- **תשתית למידת עמוקה (Deep Learning Framework):** המערכת מבוססת על PyTorch (גרסה 2.4.0). התשתית מקונפגת עם תמיכה ב-CUDA 12.1 (cu121), מה שמאפשר הרצת פעולות טנזורים כבדות על גבי ה-GPU.

8.2 ספריות אלגוריתמיות ומודלים

- הפרויקט עושה שימוש בחבילות ייעודיות למימוש הארכיטקטורה המולטי-מודאלית:
- **רשת Mamba:** שימוש בספריות mamba-ssm (גרסה 2.2.5) ו-causal-conv1d-1 (גרסה 2.2.5) המספקות מימוש יעיל ב-Cuda של ה-State Space Models עבור עיבוד הרצף הטמפורלי.
- **מודל ראייה (Vision Model):** שימוש בספריית open_clip_torch (גרסה 3.3.0) לטעינת מודל ה-ViT-B-32 לחילוץ המאפיינים מהתמונות.

- **עיבוד נתונים אופרטיבי:** שימוש בספריות סטנדרטיות כגון numpy (גרסה 2.2.6) לפעולות מתמטיות, ו-Pillow לעיבוד גולמי של התמונות לפני הזנתן למודלים.

8.3. ממשק משתמש וויזואליזציה (UI)

- **פיתוח Dashboard:** ממשק המשתמש (app.py) מפותח באמצעות ספריית Streamlit. ספרייה זו נבחרה משום שהיא מאפשרת יצירה מהירה של ממשקי Web אינטראקטיביים בפיתוח, התומכים בהצגת גרפים, ניהול היפר-פרמטרים וסטרימינג של נתונים בזמן אמת מבלי לדרוש פיתוח Front-end נפרד.

9. מגבלות המערכת והנחות יסוד (System Limitations & Assumptions)

פרק זה מפרט את מגבלות הארכיטקטורה הנוכחית ואת התנאים שבהם המערכת עלולה להציג ביצועים חסרים, במטרה לשקף בגרות הנדסית והבנה של גבולות הפתרון.

9.1. יכולות הכללה חזותית (Visual Generalization Constraints)

רכיב הראייה במערכת (OpenCLIP) פועל במצב הערכה קפוא (eval) ואינו עובר כוונון עדין (Fine-tuning) על תמונות היעד. משמעות הדבר היא:

- המערכת נשענת על הידע המוקדם של המודל ואוצר המילים החזותי שלו.
- ייתכן קושי בזיהוי אובייקטים בעלי צורה חריגה, שקיפות גבוהה (כמו כוסות זכוכית), או טקסטורות שאינן מיוצגות היטב במרחב הלטנטי המקורי של המודל.

9.2. מיקוד משימות (Task Specificity)

מכיוון שהמודל תוכנן ואומן בלעדית על תת-קבוצת הנתונים (Pick and Place) pnp, מרחב הפעולה שלו מוגבל לדינמיקה של הזזת חפצים.

- המערכת אינה מסוגלת לבצע משימות הדורשות הפעלת כוח רציף ומבוקר (כגון ניגוב משטחים) או טיפול בחומרים משתנים (כגון מזיגת נוזלים או קיפול בד).
- הפעלת המודל על סביבות אלו תוביל לחיזוי שגוי של זוויות המפרקים, שכן תבניות התנועה הטמפורליות שונות לחלוטין.

9.3. תלות בחומרה וזמן אמת (Hardware Dependencies & Latency)

חיזוי פעולות עבור מערכת רובוטית דורש תגובה בזמן אמת (Real-time control).

- המערכת כפי שהיא מוגדרת כיום תלויה לחלוטין בזמינות מעבד גרפי (GPU) התומך ב-CUDA.
- הרצת צינור המידע (חילוץ Embedding ב-OpenCLIP והסקה ב-Mamba) על גבי מעבד רגיל (CPU) תגרור זמני השהיה (Latency) גבוהים שאינם מאפשרים שליטה חלקה ותקינה בזרוע ה-WidowX-250 בזמן אמת.

10. סיכום (Conclusion)

מסמך תכנון תוכנה (SDD) זה מציג ארכיטקטורה שלמה, מודולרית ומבוססת למערכת למידה מולטי-מודאלית עבור שליטה רובוטית. הפתרון שפותח מגשר על הפער שבין קליטת מידע חזותי גולמי לבין קבלת החלטות קינמטיות מדויקות במרחב רציף של 7 דרגות חופש (DOF-7).

באמצעות שילוב הנדסי של מודל ראייה סמנטי חזק (OpenCLIP) ללא צורך באימון מחדש, יחד עם ארכיטקטורת רצף מתקדמת (Mamba SSM) לעיבוד התלות בזמן, המערכת מותאמת באופן ייעודי להתמודדות עם משימות מניפולציה (Pick and Place) מתוך מאגר הנתונים המורכב של BridgeData V2.

יתרה מכך, מעטפת הפיתוח – הכוללת ממשק משתמש אינטראקטיבי (UI) לשליטה בהיפר-פרמטרים והפרדה ברורה של מודולי התוכנה השונים (Data Loading, Vision Encoding, Sequence Modeling) – מספקת תשתית מחקרית חזקה ויעילה. תשתית זו עונה בצורה מלאה על דרישות הפרויקט, מבטיחה תהליך אימון והערכה שקוף, ומהווה בסיס יציב להמשך חקר ופיתוח בתחום הלמידה הרובוטית.