

סקירה ספרותית: מודלי Mamba ו-RoboMamba, סוגי הקלט שלהם ושכבת ה-Embedding ברובוטיקה

סטודנטית: אוריה כהן

מרצה: ד"ר שרון ילוב הנדזל

קורס: פרויקט גמר במדעי המחשב

מוסד: המכללה האקדמית אפקה

תאריך: 03/12/2025

0. הגדרות ומושגים מרכזיים (Glossary)

להלן מובאים מושגים מרכזיים המשמשים לאורך סקירה זו. מטרת מילון המושגים היא להבהיר מונחים יסודיים בתחום למידת מכונה ורובוטיקה, במיוחד בהקשרים של עיבוד רצפים, ייצוג מידע רבי-מודאלי ומודלים מתקדמים כגון Mamba. ההסברים כאן מהווים תמצית ומיועדים להקל על הקריאה של הפרקים הבאים במסמך.

0.1 עיבוד רצפים (Sequence Modeling)

תחום בלמידת מכונה העוסק במודלים המטפלים בנתונים סדרתיים לאורך זמן – כגון וידאו, טקסט רציף, נתוני חיישנים או מסלולי תנועה. זהו יסוד מרכזי במערכות רובוטיות שבהן קלט ופעולה מתרחשים בזמן.

0.2 טוקן (Token)

יחידת המידע הבסיסית שבה מודל למידת מכונה משתמש כדי לעבד רצפים. בטקסט טוקן יכול להיות מילה או חלק ממילה, ובתמונות מדובר בפאץ' (patch). ברובוטיקה, טוקנים מייצגים תמונות, מדידות חיישנים, או מצבים קינמטיים לאורך זמן.

0.3 Embedding

המרת קלט גולמי לוקטור מתמטי קומפקטי המייצג את משמעותו. תהליך זה מאפשר למודל ללמוד דפוסים, קשרים ומבנים מתוך סוגי מידע שונים.

0.4 מודאליות (Modality)

סוג מידע ייחודי, כגון תמונה, טקסט, מידע קינמטי, עומק או מדידות חיישנים. כל מודאליות מאופיינת במבנה שונה ובצורת ייצוג שונה.

0.5 רבי-מודאלי (Multimodal)

שילוב של מספר מודאליות יחד לצורך יצירת ייצוג או פעולה. ברובוטיקה מדובר בשילוב תמונות, נתוני עומק, מצב זרוע, טקסט ומדידות חיישנים ליצירת מדיניות מדויקת.

0.6 מרחב לטנטי (Latent Space)

מרחב מופשט שבו מיוצגים ה-Embeddings של הקלט לאחר דחיסה. במודלים רב-מודאליים, מרחב לטנטי משותף מאפשר לשלב סוגי מידע שונים בתהליך למידה אחיד.

0.7 Recurrent Neural Networks (RNN)

משפחת מודלים לעיבוד רצפים המשתמשת במצב פנימי (hidden state) כדי לשמור מידע מהעבר. RNN מתקשה לזכור מידע לאורך זמן רב.

0.8 Long Short-Term Memory (LSTM)

הרחבה של RNN הכוללת שערים פנימיים לשימור מידע לאורך זמן. יציבה יותר מ-RNN, אך עדיין מתקשה ברצפים ארוכים מאוד.

0.9 Vanishing Gradients

תופעה בה הגרדיאנט קטן מאוד ככל שמתארך הרצף, ומונע מהמנגנון הלימודי לעדכן את המשקלים בצורה יעילה. זוהי מגבלה מרכזית ב-RNN ו-LSTM.

0.10 Transformer

- ארכיטקטורה מודרנית המבוססת על מנגנון Self-Attention. מאפשרת עיבוד מקבילי ושילוב רב-מודאלי, אך בעלת סיבוכיות חישובית ריבועית ($O(n^2)$).
- 0.11 Self-Attention**
- מנגנון המאפשר למודל לזהות קשרים בין טוקנים שונים ברצף. מהווה את הבסיס המרכזי של Transformer.
- 0.12 State Space Models (SSM)**
- משפחת מודלים לעיבוד רצפים המתבססת על משוואות מצב ליניאריות לאורך זמן. מציעה עיבוד מהיר ויציב במיוחד ברצפים ארוכים.
- 0.13 (Structured State Space Sequence Model) S4**
- דגם מתקדם של State Space המאפשר עיבוד יציב ויעיל של רצפים ארוכים במיוחד באמצעות מבנה ליניארי מאורגן (structured), תוך שימוש בשיטות להגברת יציבות ותדרים ארוכים.
- 0.14 Mamba (Selective State Space Model)**
- מודל SSM מודרני המשלב עיבוד ליניארי עם מנגנון Selective Scan המאפשר בחירה דינמית של מידע רלוונטי. מותאם במיוחד לרצפים ארוכים ולמידע רב-מודאלי.
- 0.15 Selective Scan**
- מנגנון הבחירה הדינמי של Mamba, המהווה חלופה יעילה למנגנון ה-Self-Attention בכך שהוא מאפשר התמקדות בטוקנים חשובים במהלך הסריקה ברצף.
- 0.16 Kinematics (קינמטיקה)**
- תחום המתאר את תנועת הרובוט – מיקום, מהירות וזוויות מפרקים. כולל:
- Forward Kinematics – חישוב מיקום האנד-אפקטור על בסיס זוויות המפרקים.
 - Inverse Kinematics – חישוב זוויות הדרושות להשגת מיקום יעד.
 - Differential Kinematics – מהירויות ושינויים במצב בזמן.
- 0.17 Proprioception (פרופריוספציה)**
- קלט פנימי של הרובוט הכולל זוויות מפרקים, מהירויות, מומנטים ונתוני קינמטיקה נוספים המשקפים את "מצב הגוף".
- 0.18 Trajectory (מסלול תנועה)**
- רצף של מצבים לאורך זמן המתאר מיקום, מהירות ותאוצה. משמש ללימוד תנועה ולחיזוי פעילות רובוטית.
- 0.19 End-Effector**
- האלמנט בקצה הזרוע הרובוטית (תפסן, מברג, מצלמה) המבצע את האינטראקציה הפיזית עם הסביבה.
- 0.20 Observation Space (מרחב תצפיות)**
- כל סוגי המידע שהרובוט קולט מהסביבה – תמונות, עומק, פרופריוספציה ונתונים נוספים. משמש כקלט למדיניות (Policy).
- 0.21 Action Space (מרחב פעולות)**
- מערך הפעולות האפשריות שהרובוט יכול לבצע – תנועות במפרקים, מהירויות, פעולות דיסקרטיות ("תפוס", "שחרר") או פקודות במרחב קרטזי.
- 0.22 Policy (מדיניות פעולה)**
- פונקציה הממפה מצב (Observation) לפעולה (Action). זהו הרכיב המרכזי במודלים רובוטיים כגון – RT-1, FlowRAM, ושיטות של Imitation Learning.
- 0.23 Keyframe (מצב מפתח)**

ייצוג ביניים לאורך מסלול תנועה. במקום לחזות פעולה ישירה, המודל חוזר נקודת יעד ביניים, והרובוט מחשב את הפעולות הנדרשות להגיע אליה.

Imitation Learning 0.24

שיטה שבה הרובוט לומד לבצע משימה מתוך הדגמה אנושית. נפוצה במיוחד בלמידת תנועה.

Behavior Cloning (BC) 0.25

שיטת Imitation Learning בסיסית המתבססת על זוגות קלט-פעולה. המודל מחקה ישירות את הפעולות שביצע המומחה.

Motion Encoder 0.26

רכיב הממפה מסלולי תנועה או שינויים קינמטיים למרחב לטנטי לצורך למידה או חיזוי פעולה. משמש, בין השאר, בעבודות המבוססות על Mamba.

Vision-Language-Action (VLA) 0.27

מודלים המאחדים ראייה, שפה ופעולה לדוגמה – RT-1 ו-RT-2 – כדי לאפשר לרובוט להבין הוראות ולהגיב בהתאם.

Flow Matching 0.28

שיטה שבה המודל לומד "להתאים" בין מצב רצוי לבין פעולה המתאימה לו לפי מבנה זרימה מתמטי.

FlowRAM 0.29

מודל רובוטי המשתמש ב-Mamba כדי לאחד מידע רב-מודאלי (תמונה, עומק, קינמטיקה) ולהפיק פעולות בהתאם.

RoboMamba 0.30

גרסה יישומית של Mamba המותאמת למשימות רובוטיות, בעיקר ייצוג תנועה, שילוב קינמטיקה ומידע חזותי. אינה ארכיטקטורה חדשה אלא התאמה של Mamba לתחום הרובוטיקה.

1. מבוא

במסגרת פרויקט הגמר אאמן מודל Mamba או RoboMamba על משימות רובוטיות שיוגדרו בהמשך. מסמך זה מתמקד בשלב הראשוני של הפרויקט, וכולל סקירת מתחרים וסקירת ספרות על מודלים לעיבוד רצפים, שיטות Embedding לסוגי קלט שונים, ושילוב רב-מודאלי ברובוטיקה. מטרת הסקירה היא לבסס את הרקע התאורטי והמחקרי הנדרש להבנת התחום ולבחירת הגישה המתאימה לשלבי הפיתוח הבאים של הפרויקט.

2. סקירת מתחרים

במשימות רובוטיות מודרניות קיימות מספר ארכיטקטורות מרכזיות המהוות פתרונות חלופיים או קרובים למודלים המבוססים על Mamba. מודלים אלה מציעים יכולות שונות בעיבוד קלט רב-מודאלי, בקידוד רצפים ובביצוע משימות מניפולציה.

2.1 RT-1 ו-RT-2 (Robotics Transformer)

RT-1 ו-RT-2 (Robotics Transformer) הם גופי Transformer רחבי היקף המשלבים תמונה, שפה וקינמטיקה (Brohan et al., 2022). היתרון הוא יכולת כללית גבוהה; החיסרון הוא סיבוכיות חישובית גבוהה שמגבילה את השימוש במודל במשימות זמן אמת ובעיבוד רצפים ארוכים.

Perceiver IO 2.2

Perceiver IO הוא ארכיטקטורה כללית לקלט רב-מודאלי, המבוססת על cross-attention יעיל, ומאפשרת יצירת Embedding אחיד למידע מסוגים שונים (Jaegle et al., 2021).

2.3 מודלי Diffusion ברובוטיקה

מצוינים ביצירת תנועות מדויקות, אך איטיים ומורכבים מדי עבור משימות רציפות או אינטראקטיביות.

2.4 מודלי SSM קלאסיים (S4, LRU)

מודלי SSM קלאסיים כגון S4 ו-LRU יעילים ברצפים ארוכים ויציבים מתמטית, אך חסרים מנגנון בחירה דינמי ולכן מוגבלים בשילוב מודאליות ובדגשים לאורך רצף (Gu et al., 2021; Orvieto et al., 2023).

3. סקירת ספרות – התפתחות מודלי רצפים ועד Mamba ברובוטיקה

כשניגשתי לבנות את הפרויקט, הבנתי שהבסיס המרכזי הוא להבין איך מודלים שונים מטפלים ברצפים: איך הם זוכרים מידע, איך הם משלבים מודאליות שונות, ואיך כל זה מתחבר למשימות רובוטיות בעולם האמיתי. לכן בחרתי להתחיל ממש מהתחלה — לעבור שלב-שלב בין הדורות השונים של המודלים, להבין מה כל אחד מהם פתר, ומה היו המגבלות שהובילו לדור הבא.

3.1 הדור הראשון – RNN ו-LSTM

המודלים הראשונים שטיפלו ברצפים היו RNN. הם הציגו רעיון חשוב: שימוש במצב פנימי שמאפשר לזכור מידע מהעבר. אבל בפועל, המודלים התקשו לשמר מידע לאורך זמן בגלל תופעת Vanishing Gradients, ולכן הם התקשו להתמודד עם רצפים ארוכים ומורכבים (Orvieto et al., 2023). LSTM ו-GRU שיפרו את הנושא עם מנגנוני שערים, אך גם הם לא סיפקו פתרון יציב לרצפים ארוכים במיוחד, כמו נתוני חיישנים רציפים או וידאו. מחקר ה-(Orvieto et al., 2023) LRU הציג גרסה ליניארית ומנורמלת של RNN שהגיעה לביצועים גבוהים יותר, והדגיש כמה חשובה יציבות מתמטית בעיבוד רצפים.

3.2 התחזקות היכולת – Transformer

כשהופיע Transformer, הוא שינה לחלוטין את הגישה לעיבוד רצפים. Self-Attention אפשר למודל להתייחס לכל הטוקנים ברצף בצורה מקבילית וללמוד קשרים רחוקים בצורה יעילה מאוד. בשנים האחרונות Transformer הפך לגישה המרכזית בתחומים רבים, כולל ראייה, שפה ו-VLA. עם זאת, קיימת מגבלה משמעותית: הסיבוכיות הריבועית של המודל, ככל שהרצף ארוך יותר — העלות החישובית הופכת גבוהה מאוד, מה שמקשה להשתמש ב-Transformer ברובוטיקה שבה הזמן והיעילות קריטיים (Orvieto et al., 2023).

3.3 מעבר לחשיבה דינמית – State Space Models (SSM)

מודלי State Space Models, ובפרט S4 (Gu et al., 2021), הציגו גישה אחרת לגמרי: שימוש במערכת מצב ליניארית המתארת את התפתחות המצב לאורך זמן. הם העניקו:

- יציבות גבוהה

- טיפול יעיל ברצפים ארוכים

- סיבוכיות ליניארית

זו הייתה התקדמות משמעותית, אבל עדיין הייתה חסרה יכולת חשובה: הבחנה דינמית בין חלקי הרצף — כלומר, לדעת איזה מידע חשוב יותר ברגע נתון.

3.4 Mamba – שילוב בין יציבות ליכולת בחירה

מודל Mamba (Gu & Dao, 2023) הופיע כמענה לשתי המגבלות הגדולות:

הוא משלב בין היעילות של SSM לבין היכולת לבחור אילו חלקים ברצף חשובים יותר — בדומה ל-Attention, אבל בצורה יעילה בהרבה. הודות למנגנון Selective Scan, המודל מסוגל:

- לסרוק רצף במהירות
 - להתמקד במידע רלוונטי בלבד
 - להתמודד מצוין עם נתונים רציפים כמו תנועה, וידאו וחיישנים
- זהו חיבור שקרוב מאוד למה שמודלים ברובוטיקה צריכים (Gu & Dao, 2023).

3.5 Embedding רב-מודאלי – חיבור בין תמונות, טקסט וקנימטיקה

ברובוטיקה הקלט אינו אחיד: הוא כולל פריימים ממצלמות, עומק, נתוני מפרקים, טקסט, ואפילו ענני נקודות. Perceiver IO (Jaegle et al., 2021) הציג דרך גנרית להמיר כל סוג מידע ל-Embedding אחיד, מה שמאפשר בהמשך למודלים כמו Mamba לעבד את הכול במסגרת אחת.

3.6 Transformers ברובוטיקה – הדוגמה של RT-1

RT-1 (Brohan et al., 2022) היה אחד המודלים הראשונים שהדגים שימוש ב-Transformer בקנה-מידה גדול ברובוטיקה: הוא שולב עם 130,000 הדגמות ו-700 משימות שונות. המגבלה המרכזית נותרה בעינה: Transformer מתקשה לעבד רצפים ארוכים ונתונים רציפים בזמן אמת בגלל עלות חישובית גבוהה.

3.7 Mamba מגיעה לרובוטיקה – יישומים עדכניים

3.7.1 Mamba כ-Motion Encoder (Tsuji, 2025)

Tsuji הדגים שמודל Mamba מסוגל לקודד תנועה בצורה יציבה ומדויקת. זה הופך אותו לכלי יעיל למשימות של Imitation Learning ולחיזוי תנועה (Tsuji, 2025).

3.7.2 FlowRAM – שילוב ראייה, גאומטריה ותנועה (Wang et al., 2025)

FlowRAM מציג שילוב בין Mamba לבין Conditional Flow Matching. הוא מטפל:

- בתמונות
- נקודות תלת-ממד
- הוראות טקסט
- פרופריוספציה

ומצליח במשימות מניפולציה עדינות כמו הכנסת USB, הברגת ברגים ועוד (Wang et al., 2025).

3.7.3 RoboMamba

רובו-ממבה אינה ארכיטקטורה חדשה אלא התאמה של Mamba למשימות רובוטיות — בעיקר ייצוג תנועה ושילוב מודאליות.

3.8 סיכום – מ-RNN ועד Mamba: כיוון ההתפתחות ברור

מהתפתחות המודלים עולה מגמה עקבית: המעבר לגישות יציבות, יעילות וחכמות שיכולות להתמודד עם רצפים ארוכים ומידע מורכב. Mamba משלבת בין:

- יציבות מתמטית
- יעילות חישובית

- בחירה דינמית של מידע
 - התאמה טבעית לנתונים רב־מודאליים
 - ביצועים גבוהים במשימות רובוטיות
- ולכן היא משמשת בסיס מצוין למודל שאפתח בפרויקט.

3.9 טבלה מסכמת של המודלים ותרומתם

מודל	שנה	מה הוא פותר?	מגבלות	רלוונטיות לפרויקט
RNN	~1990	ניסיון ראשון לשמר זיכרון רציף לאורך זמן.	Vanishing Gradients, קושי ברצפים ארוכים.	רקע היסטורי, לא רלוונטי ליישום.
LSTM / GRU	1997–2014	שיפור משמעותי בזיכרון ארוך טווח באמצעות שערים.	ביצועים נמוכים בנתונים ארוכים ועתירי מידע.	חשוב להבנת מושג ה"state", אך אינו מתאים לרובוטיקה מודרנית.
Transformer	2017	Self-Attention – לומד תלות רחוקה ביעילות.	סיבוכיות ריבועית, יקר לרצפים ארוכים.	בסיס למודלים כמו RT-1, אך אינו יעיל למשימות רציפות.
S4 (State Space)	2021	עיבוד יציב וליניארי של רצפים ארוכים מאוד.	לא "בוחר" מידע חשוב – ליניארי מדי.	צעד חשוב בדרך ל-Mamba.
LRU	2023	החייאת RNN באמצעות יציבות ליניארית.	עדיין פחות גמיש מ-SM.	רקע תיאורטי – מדגיש מעבר ליציבות.
Mamba	2023	שילוב Selective - Scan + SSM יעילות + בחירה דינמית.	מודל חדש, מעט יישומים מבוססים.	המודל המרכזי הרלוונטי ביותר לפרויקט.
RoboMamba	2024–2025	התאמת Mamba לרובוטיקה, בעיקר תנועה וקינמטיקה.	לא ארכיטקטורה חדשה.	אחת משתי האופציות שאבחן.
FlowRAM	2025	שילוב Mamba עם Flow Matching, משימות עדינות ומדויקות.	מורכב, פחות מתאים לריצה בזמן אמת.	נותן אינדיקציה לכיוון התחום.

3.10 פסקת דיון – מה הספרות אומרת לנו?

הסקירה מציגה תמונה ברורה של התפתחויות בתחום עיבוד הרצפים לרובוטיקה. ניתן לראות שלושה כיווני התפתחות מרכזיים:

3.10.1 מעבר מ"מודלים זוכרים" ל"מודלים מבינים דינמיקה"

בעוד RNN/LSTM ניסו לשמר מידע, המודלים החדשים כמו S4 ו-Mamba מבינים את דינמיקת הרצף כיחידה מתמטית יציבה – מה שהופך אותם מתאימים הרבה יותר לתנועה רובוטית.

3.10.2 דרישה הולכת וגדלה ליעילות


Transformers מתאימים למשימות קצרות או סטטיות, אך לא מצליחים לעבוד ביעילות בפריימים רציפים או נתונים ארוכים. SSM ו-Mamba נותנים מענה ישיר לבעיה זו.

3.10.3 שילוב רב-מודאלי הוא חובה ברובוטיקה

RT-1, FlowRAM ו-RoboMamba מראים שלרובוט מודרני אין "קלט אחד" – הוא חייב לשלב תמונה + עומק + קינמטיקה + טקסט.

לכן המודלים המתקדמים ביותר הם אלו שיכולים לגשר על מודאליות שונות באופן יעיל.

3.11 תרשים התפתחות (Timeline)



תרשים 1 — התפתחות היסטורית של המודלים לעיבוד רצפים, מרשתות RNN ועד FlowRAM.

הערה:

כפי שניתן לראות בתרשים 1, כל דור נולד מצורך שלא נפתר בדור הקודם:

- RNN - בעיית זיכרון
- LSTM - מגבלות רצפים ארוכים
- Transformer - עלות חישובית גבוהה
- S4 - חוסר גמישות
- Mamba - שילוב יעילות + בחירה
- RoboMamba/FlowRAM - יישום ברובוטיקה

4. ביבליוגרפיה (מקורות)

- 1 Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., Dabis, J., Finn, C., ... Zitkovich, B. (2022). *RT-1: Robotics Transformer for Real-World Control at Scale*. <https://doi.org/10.48550/arxiv.2212.06817>
- 2 Gu, A., Goel, K., & Ré, C. (2021). *Efficiently Modeling Long Sequences with Structured State Spaces*. <https://doi.org/10.48550/arxiv.2111.00396>
- 3 Gu, A., & Dao, T. (2023). *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*. <https://arxiv.org/abs/2312.00752>
- 4 Jaegle, A., Borgeaud, S., Alayrac, J.-B., Doersch, C., Ionescu, C., Ding, D., ... Carreira, J. (2021). *Perceiver IO: A General Architecture for Structured Inputs & Outputs*. <https://doi.org/10.48550/arxiv.2107.14795>
- 5 Orvieto, A., Smith, S. L., Gu, A., Fernando, A., Gulcehre, C., Pascanu, R., & De, S. (2023). *Resurrecting Recurrent Neural Networks for Long Sequences*. <https://doi.org/10.48550/arxiv.2303.06349>
- 6 Tsuji, T. (2025). *Mamba as a Motion Encoder for Robotic Imitation Learning*. IEEE Access, 13, 69941–69949. <https://ieeexplore.ieee.org/document/10966860>
- 7 Wang, S., Wang, L., Zhou, S., Tian, J., Li, J., Sun, H., & Tang, W. (2025). *FlowRAM: Grounding Flow Matching Policy with Region-Aware Mamba Framework for Robotic Manipulation*. CVPR Proceedings, 12176–12186. <https://ieeexplore.ieee.org/document/11093664>